

Предсказание преобразований изображений в группе D_4

Авторегрессивная модель над генераторами r и s

Щербухина Анастасия Викторовна
2 курс, МФТИ ФПМИ

Идея и основа работы

Идея

Вместо ответа “картинки похожи” модель должна восстановить преобразование между изображениями:


$$f_{\theta}(I_1, I_2) \rightarrow g \in D_4 \cup \{\emptyset\}.$$

За основу взята статья *Evidential Image Matching: Predicting Transformation Sequences to Derive One Image from Another*.

$$f_{\theta} : \mathbb{R}^{H \times W \times C} \times \mathbb{R}^{H \times W \times C} \rightarrow T^*$$

Оригинальный проект: [DorinDaniil/Image-Transform-Predict](#)

Схема evidential image matching



- ▶ вход: пара изображений (I_1, I_2) ;
- ▶ выход: последовательность преобразований $t = (t_1, \dots, t_k)$;
- ▶ если связи нет, последовательность пустая или специальный токен.

Почему повороты всё ещё проблема

Визуальная похожесть $\neq$ понимание преобразования

Современная модель может увидеть, что изображения похожи, но не всегда надёжно отвечает, какой оператор связывает их.

- ▶ r : поворот на 90° ;
- ▶ $r^3 = r^{-1}$: поворот на 270° ;
- ▶ s : отражение;
- ▶ sr^k : отражение с поворотом.

Обычная постановка

$$\text{sim}(I_1, I_2) \rightarrow [0, 1]$$

Наша постановка

$$f_\theta(I_1, I_2) \rightarrow g \in D_4 \cup \{\emptyset\}$$

Вместо “похоже” нужен объяснимый ответ: r , r^2 , r^3 , s , sr , sr^2 , sr^3 или $\emptyset$.


Наша адаптация: чистая задача на группе D_4

Диэдральная группа квадрата

$$D_4 = \langle r, s \mid r^4 = e, s^2 = e, srs = r^{-1} \rangle$$

$$D_4 = \{e, r, r^2, r^3, s, sr, sr^2, sr^3\}$$

- ▶ r задаёт поворот на 90° ;
- ▶ s задаёт отражение;
- ▶ $\emptyset$ означает, что изображения не связаны допустимым элементом D_4 .



positive: $I_2 = g(I_1)$
negative: $I_2 \neq g(I_1) \forall g \in D_4$

Почему не flat-классификация

Flat classifier

$$(I_1, I_2) \rightarrow \{e, r, r^2, r^3, s, sr, sr^2, sr^3, \emptyset\}$$

Минус: классы выглядят независимыми, хотя между ними есть групповые соотношения.


Авторегрессивный decoder

$$p_{\theta}(w \mid I_1, I_2) = \prod_t p_{\theta}(w_t \mid w_{<t}, c)$$

Модель строит слово над генераторами, то есть учится композиции преобразований.

Элемент	Каноническое слово	Интерпретация
r^2	$r r$	два поворота на 90°
sr^3	$s r r r$	отражение и три поворота

Граф Кэли D_4



Интерпретация

Вершина графа — элемент группы.
Рёбра — применение генераторов r и s .

$$g = a_1 a_2 \dots a_k, \quad a_i \in \{r, s\}.$$

Авторегрессивный decoder можно понимать как модель, которая выбирает путь по графу Кэли.

Канонические ответы

Элемент D_4	Target-последовательность	Длина
e	e	1
r	r	1
r^2	$r r$	2
r^3	$r r r$	3
s	s	1
sr	$s r$	2
sr^2	$s r r$	3
sr^3	$s r r r$	4
$\emptyset$	[NULL]	1

Почему это важно

Каноническая форма позволяет сравнивать ответы не как случайные строки, а как элементы группы с фиксированным представлением.

Две модели в проекте

Модель 1: sequence model

Предсказывает применённый элемент:

$$I_2 = g(I_1), \quad g \in D_4 \cup \{\emptyset\}.$$

Пример: если $I_2 = r^3(I_1)$, target равен $r r r$.

Первая модель отвечает “какой g применён”. Вторая проверяет, научилась ли система работать с групповой композицией и обратными элементами.

Модель 2: completion model

Получает prefix и достраивает продолжение до корректного эквивалента или завершения.

Пример: r нужно дополнить $r r r$, потому что $r \cdot r^3 = e$.

Почему понадобилась completion model

Проблема


Модель может предсказать g , но это ещё не значит, что она понимает обратное преобразование g^{-1} .

$$I_1 \xrightarrow{g} I_2, \quad I_2 \xrightarrow{g^{-1}} I_1.$$

Элемент	Обратный элемент
r	r^3
r^2	r^2
r^3	r
s	s

Ключевой случай: $s^{-1} = s$. Если модель не может достроить s до эквивалентного завершения, она не усвоила алгебру отражения.

Архитектура модели



$$z_1 = E_\phi(I_1), \quad z_2 = E_\phi(I_2), \quad c = \text{Fuse}(z_1, z_2),$$
$$p_\theta(w \mid I_1, I_2) = \prod_{t=1}^T p_\theta(w_t \mid w_{<t}, c).$$

EfficientNet как encoder

Математически

$$E_{\text{eff}}(I) = \text{Pool}(\text{CNN}(I)) \in \mathbb{R}^d, \quad c = P([E_{\text{eff}}(I_1), E_{\text{eff}}(I_2)]).$$

- ▶ EfficientNet строит признаки через локальные свёрточные фильтры.
- ▶ Такие признаки чувствительны к краям, углам, текстурам и их ориентации.
- ▶ Поэтому EfficientNet лучше подходит для различения направленных поворотов r и r^3 .

ViT как encoder


Математически

$$I \rightarrow (p_1, \dots, p_n), \quad x_i = W_p p_i + \text{pos}_i, \quad H = \text{Transformer}(x_1, \dots, x_n).$$

- ▶ ViT разбивает изображение на патчи и связывает их через self-attention.
- ▶ Он хорошо ловит глобальные зависимости между частями изображения.
- ▶ Но в нашей задаче направленность поворота может теряться: модель путала r и r^3 .


Наглядное сравнение encoder'ов

EfficientNet



локальная ориентация → сильный
сигнал для поворотов

ViT



глобальные связи → слабее
направленность r vs r^3

Неудачный эксперимент с ViT

Наблюдение

ViT часто путал r и r^3 : модель видела факт поворота, но хуже восстанавливала его направление.

$$\begin{aligned} r &= \text{поворот на } 90^\circ, \\ r^3 &= r^{-1} = \text{поворот на } 270^\circ. \end{aligned}$$

Математическая гипотеза

ViT выучил принадлежность к подгруппе вращений $\langle r \rangle$, но неустойчиво выучил ориентацию генератора.

Формально

$$E_{\text{vit}}(I, r(I)) \approx E_{\text{vit}}(I, r^{-1}(I)).$$

Данные для sequence model

Положительные пары

$$I_2 = g(I_1), \quad g \in D_4$$

target — каноническое слово для g .

Отрицательные пары

$$I_2 \neq g(I_1) \quad \forall g \in D_4$$

target — специальный токен $\emptyset$.

Пример	Target	Смысл
$I_2 = r(I_1)$	r	поворот на 90°
$I_2 = sr^2(I_1)$	$s r r$	отражение и два поворота
unrelated	$\emptyset$	допустимого преобразования нет

Данные для completion model

Задача

По prefix нужно предсказать continuation, который даёт корректное завершение или эквивалентную каноническую форму.

$$a_1 \dots a_k b_1 \dots b_m = \text{target}.$$

Для восстановления обратного:

$$b_1 \dots b_m = (a_1 \dots a_k)^{-1}.$$

Prefix	Continuation	Почему
r	$r r r$	$r^4 = e$
r^2	$r r$	$r^2 r^2 = e$
s	s	$s^2 = e$

Метрики

Строгие метрики

$$\text{Acc}_{\text{seq}} = \frac{1}{N} \sum_i \mathbf{1}[\hat{t}_i = t_i]$$

$$\text{Acc}_{\text{tok}} = \frac{\text{\#correct non-PAD tokens}}{\text{\#non-PAD tokens}}$$

Диагностические метрики

- ▶ Precision / Recall / F1;
- ▶ edit distance и normalized edit distance;
- ▶ confidence;
- ▶ качество по доменам и классам.

Special tokens обрабатываются явно: [PAD] и [BOS] исключаются из token-метрик, [EOS] и [NULL] учитываются.

Efficient sequence model: основные результаты

96.67%

Sequence Accuracy

96.69%

Token Accuracy

98.68%


Avg Confidence

0.0226

Norm. Edit Dist.

- ▶ checkpoint: EfficientNet + Transformer decoder;
- ▶ heldout: 16 200 пар;
- ▶ target: применённый элемент g , где $I_2 = g(I_1)$.
- ▶ macro class F1: 87.01%;
- ▶ canonical rate: 100%;
- ▶ ошибки в основном важны как структура: какие элементы группы путаются.

Efficient sequence model: качество по доменам




Что показывает график

Сравнение Sequence Accuracy, Token Accuracy и F1 на разных визуальных доменах.

Домены с простой геометрией обычно легче, а стилизованные или шумные изображения дают больше ошибок.

Efficient sequence model: матрица ошибок




Как читать

Диагональ — верные элементы D_4 .

Внедиагональные клетки показывают, какие преобразования модель путает.

Особенно важны ошибки вида $r \leftrightarrow r^3$: это не просто ошибка класса, а ошибка ориентации в циклической подгруппе.

Efficient sequence model: top error pairs




Зачем нужен

Этот график показывает не среднюю точность, а структуру самых частых неверных переходов.


Его удобно сопоставлять с графом Кэли: ошибка — это переход в неправильную вершину группы.

Efficient sequence model: confidence




Подпись: confidence показывает, насколько модель уверена в greedy decoding.

Efficient sequence model: edit distance



Подпись: edit distance показывает, на сколько токенов предсказанная последовательность отличается от target.

Efficient sequence model: token-level confusion



Почему это важно

Sequence accuracy строгая, но token confusion показывает, какой именно шаг авторегрессивной цепочки ломается.

Для D_4 это помогает отличать ошибки генератора r от ошибок генератора s .

Completion model: основные результаты

98.41%

Completion Exact

97.81%

Token Accuracy

99.35%


Avg Confidence

0.0111

Norm. Edit Dist.

- ▶ heldout: 48 600 completion-примеров;
- ▶ prefix strategy: all;
- ▶ target: продолжение до корректного завершения.
- ▶ macro class F1: 88.51%;
- ▶ модель проверяет композицию и обратные элементы;
- ▶ это ближе к обучению алгебре D_4 , чем простая классификация.

Completion model: качество по доменам




Что показывает

Насколько стабильно модель достраивает последовательности на разных типах изображений.

Если completion зависит от image-pair embeddings, домен всё ещё влияет на уверенность и ошибки.

Completion model: confusion matrix



Смысл


Ошибка completion — это не только неверный label, а неверная групповая композиция.

Для защиты результата важно показать, что модель редко путает канонические завершения.

Completion model: качество по prefix

Completion: качество по длине prefix

Чем длиннее prefix, тем меньше хвост нужно достраивать.



Интерпретация


График показывает, какие начальные цепочки сложнее достраивать.

Это наиболее прямой анализ того, насколько модель понимает continuation-задачу.

Completion model: зависимость от длины continuation


Completion: качество по длине continuation

Длина continuation — сколько токенов модели нужно достроить до EOS.




Completion: истинная длина vs предсказанная длина

В клетках количество examples. Диагональ означает, что модель угадала длину continuation.




Чем длиннее continuation, тем больше шагов должен правильно сделать decoder, поэтому эта диагностика важнее простой общей ассигуры.

Completion model: confidence diagnostics



Подпись: confidence показывает уверенность модели при генерации continuation.

Completion model: edit distance



Подпись: edit distance показывает, насколько предсказанное продолжение отличается от правильного continuation.

Ошибки как движение по графу

Пример

$$\text{target} = r, \quad \text{prediction} = r^3.$$

Модель видит поворот, но путает направление генератора.



Главный экспериментальный вывод

Что сработало

EfficientNet + autoregressive decoder хорошо решает задачу предсказания g и completion-задачу.

- ▶ sequence model: 96.67% exact match;
- ▶ completion model: 98.41% exact match;
- ▶ ответы остаются интерпретируемыми как слова над генераторами.

Что важно

D4-задача оказалась не просто классификацией, а задачей изучения алгебраической структуры преобразований.

- ▶ ошибки r/r^3 имеют математический смысл;
- ▶ completion model проверяет понимание обратных элементов;
- ▶ граф Кэли помогает объяснять ошибки.

Обобщение на другие группы

Общая постановка

Пусть есть группа

$$G = \langle S \mid R \rangle,$$

где S — генераторы, а R — соотношения. Тогда модель может предсказывать слово над S .

Группа	Что моделирует	Что усложняется
C_n	дискретные повороты	больше классов вращений
D_n	симметрии n -угольника	больше отражений и композиций
S_n	перестановки	быстрый рост числа элементов
discretized $SE(2)$	сдвиги и повороты	длинные слова и непрерывная геометрия

Почему сложные группы требуют больше обучения

Комбинаторный рост

Если $|S|$ генераторов и длина слова k , то:

$$\#words(k) = |S|^k.$$

Но есть эквивалентности

Разные слова могут задавать один элемент:

$$w_1 \sim w_2 \iff [w_1]_G = [w_2]_G.$$

Поэтому модель должна учить не только визуальные признаки, но и факторизацию пространства слов по групповым соотношениям.

similarity matching $\longrightarrow$ evidential transformation prediction

- ▶ Статья дала исходную идею: предсказывать последовательность преобразований между изображениями.
- ▶ Мы адаптировали задачу к группе D_4 : $g \in D_4 \cup \{\emptyset\}$.
- ▶ Sequence model предсказывает применённый элемент g .
- ▶ Completion model проверяет понимание композиции и обратных элементов.
- ▶ Ошибки можно объяснять математически через граф Кэли и структуру группы.

Следующий эксперимент: переход от D_4 к D_n

Идея

Проверить, сохраняется ли та же архитектура, если вместо симметрий квадрата взять симметрии правильного n -угольника:

$$D_n = \langle r, s \mid r^n = e, s^2 = e, srs = r^{-1} \rangle.$$

Что меняется

- ▶ элементы: r^k и sr^k , где $k = 0, \dots, n-1$;
- ▶ канонические слова становятся длиннее;
- ▶ граф Кэли растёт с 8 до $2n$ вершин.

Что измерять

- ▶ ассигасу как функцию n ;
- ▶ ошибки $r^k \leftrightarrow r^{-k}$;
- ▶ качество completion для длинных обратных слов.

- ▶ Dorin, Varlamova, Grabovoy. *Evidential Image Matching: Predicting Transformation Sequences to Derive One Image from Another.*
- ▶ Оригинальный GitHub: [DorinDaniil/Image-Transform-Predict](#)
- ▶ Мой GitHub: [Anana7yk/ImageTransformPredictD4](#)